

Uso de Redes Bayesianas Gaussianas para comprender el efecto de biomarcadores en la Enfermedad renal crónica: Un análisis probabilístico



Tecnológico
de Monterrey

Jessica Milagros Cordero Rivera¹ Diego Rodrigo González Ramírez¹

Jose Ángel Lechuga Carrasco¹ Julio Lizárraga Beltrán¹

¹Escuela de Ingeniería y Ciencias

Matrículas: A01647083 —A01647198 —A00228198 —A01743628

Palabras Clave: enfermedad crónica renal, red bayesiana, red bayesiana gaussiana, asistencia médica, análisis probabilístico

6 de septiembre de 2026

Resumen

La enfermedad renal crónica (ERC) es una pérdida progresiva de la función renal que afectó a más de 800 millones de personas en 2017, con frecuencia subdiagnosticada por presentar síntomas en etapas avanzadas. Su detección temprana podría reducir significativamente su carga clínica y económica. El siguiente estudio empleó un enfoque cuantitativo no experimental basado en redes bayesianas gaussianas (GBN) para modelar las relaciones de dependencia probabilística entre biomarcadores clínicos asociados a la ERC, utilizando la base de datos ckd.csv. Se construyeron tres grafos acíclicos dirigidos (DAGs) con distintos subconjuntos de variables, definidos con apoyo de estudiantes y profesores de medicina, ajustados con `bn.fit()` en R (paquete `bnlearn`) y evaluados mediante BIC y AIC.

1. Introducción

La enfermedad renal crónica (ERC) es la pérdida progresiva de la función de los riñones, afectando su función de eliminar residuos y exceso de agua del cuerpo. Al encontrarse en una etapa tardía del ERC el paciente puede experimentar síntomas como, entre otros:

- Piel anormalmente oscura o clara
- Dolor de huesos
- Problemas para concentrarse o pensar
- Fasciculaciones musculares o calambres
- Susceptibilidad a hematomas
- Sed excesiva
- Hinchazón en las manos y en los pies

A muchas personas no se les diagnostica la ERC sino hasta que han perdido gran parte de su función renal.[1]. En 2017 la ERC afectó a más de 800 millones de personas y su tasa de mortalidad ha estado en aumento en este siglo. Además, debido a otras enfermedades como la diabetes mellitus y la obesidad, el riesgo de padecer ERC aumenta aún más y con ello, sus complicaciones [2].

Es evidentemente claro que la identificación y diagnóstico de la ERC beneficiaría; para unas, La calidad de vida de millones de personas que podrían desarrollar esta enfermedad en un futuro; y para otras, evitar fallecer por esta enfermedad o complicaciones derivadas de ella. Los estudios epidemiológicos han concientizado sobre el problema de la ERC no diagnosticada y sugieren que su detección y tratamiento tempranos reducirán la carga mundial que suponen los pacientes que necesitan diálisis [3].

Sin embargo, la prevención y diagnóstico temprano de la ERC no es una tarea sencilla, esto se debe principalmente a que hay una gran cantidad de factores que afectan al desarrollo de esta enfermedad: La dieta, consumo de drogas, predisposición genética, y otras enfermedades son posibles factores a considerar para la detección temprana de la ERC. Esta idea fue explorada por Taal et al. Proponen que los factores de riesgo de progresión de la ERC se incorporen a un sistema de puntuación multivariable que permita predecir el riesgo futuro de un individuo de padecer insuficiencia renal terminal. Esto permitiría realizar pruebas específicas de la ERC en la población e identificar a los pacientes con alto riesgo de progresión de la ERC para aplicarles una intervención más intensiva. [3].

El uso de biomarcadores para la predicción del desarrollo de la ERC ha sido explorada de manera muy efectiva por Navdeep et al. Dónde se realizaron diversos modelos predictivos con el objetivo de poder validar los modelos que predigan la progresión de la ERC. El modelo más preciso incluía la edad, el sexo, la Tasa de Filtración Glomerular estimada, la albuminuria, el calcio sérico, el fosfato sérico, el bicarbonato sérico y la albúmina sérica. [4]. Esto nos muestra la importancia de los biomarcadores para la predicción de la ERC.

Si bien estos enfoques muestran ser bastante efectivos, nuestro trabajo será enfocado hacia el análisis de los biomarcadores de una persona a través de una red bayesiana gaussiana (GBN). Las GBN son modelos probabilísticos que permiten mostrar las relaciones de causalidad entre distintas variables numéricas con distribución normal utilizando un DAG. Las redes bayesianas resultan útiles para modelar problemas médicos complejos que requieren razonamiento en condiciones de incertidumbre. El gran interés que se muestra este tema queda reflejado en la abundante bibliografía que propone redes de Bayes para el ámbito médico y en el esfuerzo que se está dedicando a nivel mundial al desarrollo de estas redes para apoyar la toma de decisiones clínicas [5].

En este trabajo se utiliza la base de datos ckd.csv, una base de datos que contiene 400 registros sobre diferentes marcadores para una muestra de pacientes con y sin ERC. Con la información numérica disponible se construyeron tres GBN. El modelo busca analizar las relaciones probabilísticas entre distintos biomarcadores de los pacientes de la base de datos.

Posterior a ello se realizaron seis consultas probabilísticas orientadas a estudiar cómo el nivel de ciertos biomarcadores afectan a otros, y cómo ciertos niveles de biomarcadores influyen en el diagnóstico de la ERC.

El objetivo de este análisis es implementar un modelo probabilístico que ayude a comprender cómo la interacción y dependencias de estos biomarcadores influyen en el diagnóstico de la ERC para descubrir tendencias tempranas dentro de los biomarcadores que podrían apuntar al desarrollo de la ERC y actuar con base en esa información.

2. Metodología

2.1. Enfoque y tipo de estudio

Se empleó un enfoque cuantitativo, correlacional, no experimental, basado en el uso de GBN para encontrar las relaciones de dependencia probabilística entre los biomarcadores.

2.2. Fuente de datos

Se nos otorgo una base de datos en un archivo .csv con el nombre ckd.csv, esta base de datos cuenta con las siguientes variables:

- age: Age.
- bp: Blood pressure.
- sg: Specific gravity.
- al: Albumin.
- su: Sugar.
- rbc: Red blood cells.
- pc: Pus cell.
- pcc: Pus cell clumps.
- ba: Bacteria.
- bgr: Blood glucose random.
- bu: Blood urea.
- sc: Serum creatinine.
- sod: Sodium.
- pot: Potassium.

- hemo: Hemoglobin.
- pcv: Packed cell volume.
- wc: White blood cell count.
- rc: Red blood cell count.
- htn: Hypertension.
- dm: Diabetes mellitus.
- cad: Coronary artery disease.
- appet: Appetite.
- pe: Pedal edema.
- ane: Anemia.
- class: Diagnosis.

Adicionalmente a esto, entrevistamos a profesores y alumnos de la escuela de medicina del Instituto Tecnológico y de Estudios Superiores de Monterrey, que esten familiarizados con el ERC, para que nos ayudaran a generar 3 DAG's que represente las relaciones de dependencia, ademas de esto, a las personas mas especialistas en el tema se les solicito que nos ayudaran a proponer 2 queries para poderlas resolver utilizando nuestro modelo.

2.3. Herramientas

Todos los análisis probabilísticos se realizaron utilizando entorno de desarrollo integrado RStudio (v2026.08.2), utilizando el lenguaje de programación estadístico R (v4.5.3) [6] mediante el sistema de código abierto Quarto (v1.8.25), utilizando los paquetes bnlearn (v5.2.1)[7] y tidyverse (v2.0.0).

2.4. Preprocesamiento

Durante este proceso se redujo el tamaño de las DAG's para que solo tuvieran las variables que se iban a utilizar para la DAG respectiva, así mismo, se limpiaron los datos en todas las DAG's utilizando la función `na.omit` en Rstudio para que no existiera ninguna fila con datos vacíos. Para la primera DAG solo se seleccionaron las variables siguientes: `sod`, `pot`, `bp`, `sc`, `bu`. Para la segunda DAG se seleccionaron las siguientes: `sod`, `bp`, `sc`. Y para la tercera DAG se utilizaron: `bgr`, `su`, `sg`, `al`, `sc`, `bu`, `pot`, `sod`, `bp`, `rc`, `hemo`, `pcv`, para esta tercera DAG también se convirtieron todas las variables a tipo numéricas.

2.5. Construcción y selección del modelo global

Para la construcción de las DAGs se utilizó el criterio de 3 estudiantes de la escuela de medicina de 5to semestre, 2 del Tecnológico de Monterrey campus Guadalajara y 1 de la Universidad Autónoma de Guadalajara. Cada red fue ajustada utilizando la función de bnlearn `bn.fit()` con los valores numéricos de la base de datos `ckd.csv` y evaluada con los criterios de información BIC y AIC mediante `score()`.

2.6. Estrategia analítica por pregunta de investigación

Para cada pregunta se utilizó un DAG distinto tomando en cuenta lo que nos interesaba saber, se ajustaron con `bn.fit()` y se encontraron probabilidades condicionales con `cpquery()` (utilizando una $n = 10^6$ y verificado con ponderación por verosimilitud, `method="lw"`).

3. Aplicación

3.1. Resultados




Figura 1. DAGs propuestos para representar las relaciones de dependencia entre las variables de interés.

3.2. Discusiones

4. Conclusiones

5. Referencias

1. MedlinePlus. *Enfermedad renal crónica* Biblioteca Nacional de Medicina de los Estados Unidos. <https://medlineplus.gov/spanish/ency/article/000471.htm> (2026).

Cuadro 1

Comparación de los modelos lineales y no paramétricos mediante los criterios BIC y AIC.

DAG	BIC lineal	BIC no paramétrico	Mejor BIC	AIC lineal	AIC no paramétrico	Mejor AIC
DAG 1	-5458.132	-5465.007	Lineal (+6.875)	-5434.101	-5431.521	No param. (+2.580)
DAG 2	-3333.424	-3341.827	Lineal (+8.403)	-3318.582	-3316.674	No param. (+1.908)
DAG 3	-5693.505	-5605.652	No param. (+87.853)	-5636.931	-5481.793	No param. (+155.138)

Nota. Los valores entre paréntesis indican la diferencia entre el mejor modelo y la alternativa dentro de cada DAG.

2. Kovesdy, C. P. Epidemiology of chronic kidney disease: an update 2022. *International society of nephrology* **12**, 7-11 (1 2022).
3. Taal, M. W. y Brenner, B. M. Predicting initiation and progression of chronic kidney disease: Developing renal risk scores. *International society of nephrology* **70**, 1694-1705 (2006).
4. N, T., LA, S., J, G. y et al. A Predictive Model for Progression of Chronic Kidney Disease to Kidney Failure. *JAMA* **305**, 1553-1559 (2011).
5. Kyrimi, E., McLachlan, S., Dube, K., Neves, M. R., Fahmi, A. y Fenton, N. A comprehensive scoping review of Bayesian networks in healthcare: Past, present and future. *Artificial Intelligence in Medicine* **117**, 1553-1559 (2021).
6. R Core Team. *R: A Language and Environment for Statistical Computing* R Foundation for Statistical Computing (Vienna, Austria, 2021).
7. Scutari, M. y Denis, J.-B. *Bayesian Networks with Examples in R* 2nd. ISBN 978-0367366513 (Chapman y Hall, Boca Raton, 2021).